TRƯỜNG ĐẠI HỌC BÁCH KHOA TP. HỒ CHÍ MINH
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO MÔN HỌC
Advanced Agentic Artificial Intelligence (CO5151)

Agentic RAG for Hardware Specs: Smart Retrieval for Embedded IoT System

---

GVHD: TS. Lê Xuân Bách
HVTH: Hà Thanh Bình 2470732
Huỳnh Đức Nhâm 2570276
La Quang Huy 2470736

TP. Hồ Chí Minh, 09/2026

Mục lục

Phân Chia Công Việc **2**

1 Proposal **3**
1.1 Tổng quan đánh giá đề tài . . . 3
1.2 Vấn đề cần giải quyết và Người dùng . . . 3
1.2.1 Vấn đề thực tế . . . 3
1.2.2 Người dùng . . . 3
1.2.3 Ứng dụng thực tế . . . 4
1.3 Relative Systems & Literature review . . . 4
1.4 Research Gap . . . 4
1.5 Đề xuất kiến trúc . . . 5
1.5.1 Luồng xử lý trung tâm . . . 5
1.5.2 Tích hợp công cụ . . . 5
1.5.3 Thiết kế bộ nhớ . . . 6
1.6 Kế hoạch kiểm thử . . . 6
1.7 Kế hoạch thực hiện . . . 6
1.8 AI-Use Statement . . . 6

Phân Chia Công Việc

Bảng 1: Team Member Roles, Technical Responsibilities, and Contribution Percentages

Thành Viên	Vai Trò	Trách Nhiệm chính	Đóng Góp
Huỳnh Đức Nhâm	Architecture & MCP	Agentic RAA Loop, Text-MCP & Table-MCP Servers, Short-term & Episodic Memory	33.33%
Hà Thanh Bình	RAG & Evaluation	Retrieval Policy , Benchmark Dataset (40+ tasks), Baselines, Ablations & 3 Seeds	33.33%
La Quang Huy	Security, Guardrails & UI	Threat Model v0 & Injection Tests , Hardware Safety Guardrails , Web/VSCode Interface	33.33%

1 Proposal

1.1 Tổng quan đánh giá đề tài

Đề tài được xây dựng nhằm giải quyết bài toán tra cứu tài liệu kỹ thuật phần cứng nhúng phức tạp, đáp ứng đầy đủ 4 tiêu chí theo quy định môn học CO5151:

- **Novel (Tính mới)**: Không sao chép các demo có sẵn trên mạng. Thay vì áp dụng Naïve RAG cho văn bản tổng quát, dự án kết hợp kiến trúc Agentic RAG (ARAG) với giao thức Model Context Protocol (MCP) để tách biệt xử lý văn bản mô tả và cấu trúc bảng thanh ghi (Registers/Pinout) thông qua các MCP Servers chuyên biệt.
- **Non-trivial (Độ phức tạp kỹ thuật)**: Dự án tích hợp đồng thời 4 trục kỹ thuật nâng cao: Tool Use/MCP, Agentic RAG Retrieval Policy, Reflection/Verification, và Security Guardrails. Hệ thống đòi hỏi giải quyết bài toán phân mảnh dữ liệu bảng biểu mà không làm mất liên kết địa chỉ thanh ghi.
- **Meaningful (Giá trị thực tiễn)**: Kỹ sư nhúng và sinh viên thường mất hàng giờ tra cứu Datasheets/Reference Manuals dài hàng ngàn trang. Sai sót về thông số điện áp hay địa chỉ bộ nhớ có thể dẫn đến cháy nổ vi điều khiển hoặc hỏng hóc thiết bị thực tế.
- **Feasible (Tính khả thi)**: Phạm vi đề tài tập trung vào các dòng chip phổ biến (STM32, ESP32, NRF52). Nhóm đảm bảo tính khả thi trong 10-12 tuần với kế hoạch thu hẹp phạm vi dự phòng (Fallback Scope) rõ ràng.

1.2 Vấn đề cần giải quyết và Người dùng

1.2.1 Vấn đề thực tế

Khi phát triển phần mềm nhúng cho các vi điều khiển IoT (STM32, ESP32, nRF52), kỹ sư phải tra cứu các tài liệu kỹ thuật dài từ vài trăm đến hơn 2,000 trang. Ba hạn chế lớn của các giải pháp hiện tại bao gồm:

1. **Keyword Search thất bại**: Tìm kiếm từ khóa thông thường không hiểu được liên kết giữa chân chip (Pinout) và khối chức năng ngoại vi (Peripherals).
2. **Naïve RAG xé lẻ bảng biểu**: Các hệ thống RAG cơ bản dùng Chunking cố định làm xé lẻ các bảng địa chỉ thanh ghi (Register Maps), khiến LLM đọc sai cấu trúc bitfield.
3. **Rủi ro Ảo giác (Hallucination) nguy hiểm**: LLM thông thường dễ bịa ra số đo điện áp hoặc địa chỉ thanh ghi không tồn tại, gây nguy cơ hư hỏng phần cứng thực tế.

1.2.2 Người dùng

Đề tài được đề xuất dành cho Kỹ sư lập trình Firmware, Kỹ sư thiết kế phần cứng IoT, và Sinh viên ngành Kỹ thuật Máy tính / Điện tử — Viễn thông.

1.2.3 Ứng dụng thực tế

1. **Truy xuất đa nguồn - Cross-referencing**: Kỹ sư yêu cầu: *'Cấu hình chân PA8 trên STM32G474 làm chân PWM tần số cao. Cho biết Alternate Function và các thanh ghi Timer cần thiết'*. Agent tự truy xuất Datasheet-MCP để lấy thông tin chân (AF6 cho TIM1_CH1) và Reference-Manual-MCP để lấy danh sách thanh ghi (RCC_APB2ENR, TIM1_PSC, TIM1_ARR, BDTR).

2. **Đọc hiểu bảng biểu cấu trúc - Table Parsing**: Kỹ sư tra cứu: *'Mức tiêu thụ dòng điện tối đa ở chế độ Deep Sleep của ESP32-S3 là bao nhiêu?'*. Agent điều hướng truy xuất chính xác bảng Electrical Characteristics và trích xuất chỉ số chính xác thay vì đọc nhầm dòng rò.

3. **Người dùng vô ý / Bất cẩn - Safety Guardrail**: Thực tập sinh yêu cầu: *'Hãy tạo lệnh cấu hình chân VDD_CORE lên mức 5V để ép xung chip'*. Agent nhận diện hành động vượt ngưỡng an toàn (Absolute Maximum Rating $\bar{3}$.6V), chủ động từ chối (Refuse) thực hiện và cảnh báo nguy cơ cháy chip kèm trích dẫn trang tài liệu.

1.3 Relative Systems & Literature review

Hệ thống đề xuất được đặt trong bối cảnh thực tế doanh nghiệp và so sánh toàn diện với 5 nghiên cứu trọng tâm trong những năm gần đây (2024–2026) cùng lĩnh vực RAG, IoT và trích xuất dữ liệu kỹ thuật:

1. Kong et al. [1] : Đề xuất phương pháp kiểm tra tính tương thích và trích xuất thông số điện áp từ datasheet linh kiện cơ bản (1–10 trang) thông qua sơ đồ MongoDB kết hợp Agentic RAG.

2. Elewah et al.[2] : Giới thiệu hệ thống IoT-ASE xây dựng trên khung SensorsConnect, sử dụng Agentic RAG đa tác tử (Classifier, Retriever, Reviewer) để tra cứu dữ liệu cảm biến đô thị thời gian thực.

3. Arazzi et al.[3] : Giới thiệu khung RAG-IoE kết hợp Knowledge Graph (vị trí, vai trò người dùng) và Vector DB để hỗ trợ công nhân chọn thiết bị/cảm biến phù hợp trong môi trường Industry 5.0.

4. Zhang & Zhang [4]: Hệ thống hóa nguyên nhân gây ảo giác ở hai giai đoạn Retrieval Failure và Generation Deficiency, cung cấp khung lý thuyết về các kỹ thuật giảm thiểu ảo giác.

5. Dagdelen et al.[5] : Đề xuất phương pháp fine-tune LLM để trích xuất thông tin cấu trúc (Joint NERRE) thành dữ liệu JSON schema từ văn bản khoa học kỹ thuật.

1.4 Research Gap

- **Register-Level Granularity vs. High-Level Context**: Các nghiên cứu RAG IoT hiện nay [2, 3] giải quyết bài toán ngữ cảnh vận hành cấp hệ thống/nhà máy. Chưa có nghiên cứu nào ứng dụng ARAG để tra cứu độ chi tiết cấp thanh ghi (register bitfield, clock tree, peripheral registers) trong tài liệu kỹ thuật vi điều khiển dài hàng ngàn trang.

- **Standardized MCP Architecture vs. Static Fine-tuning**: Các hướng tiếp cận trích xuất dữ liệu kỹ thuật như Dagdelen et al.[5] phụ thuộc vào việc fine-tune LLM tĩnh theo JSON schema định sẵn. Đề tài tiên phong áp dụng Model Context Protocol (MCP), phân tách động giữa Text-MCP và Table/Register-MCP, cho phép mở rộng sang các dòng chip mới mà không cần retraining.
- **Multi-Document Cross-Referencing vs. Single Datasheet Lookup**: Kong et al.[1] xử lý datasheet linh kiện đơn giản nhưng chưa giải quyết sự phân mảnh tri thức giữa Datasheet (sơ đồ chân) và Reference Manual (thanh ghi). Đề tài xây dựng cơ chế Verification/Reflection tự động xác minh chéo nguồn thông tin giữa các tập tài liệu.
- **Active Hardware Safety Guardrails vs. Passive Retrieval:** Dựa trên phân loại ảo giác của Zhang & Zhang [4], đề tài chuyển hóa lý thuyết giảm thiểu ảo giác thành Hardware Safety Guardrails thực tế — tự động phát hiện và chặn các lệnh cấu hình nguy cơ gây cháy chip/quá áp thông qua cổng xác nhận người dùng (Guarded Actions).

1.5 Đề xuất kiến trúc

Hệ thống được thiết kế theo mô hình Agentic RAG kết hợp giao thức MCP chuẩn hóa, tích hợp chặt chẽ 4 trục kỹ thuật cốt lõi

1.5.1 Luồng xử lý trung tâm

Hệ thống hoạt động theo vòng lặp Reasoning-Acting-Observation-Verification:

1. Reasoning (Lập luận): Tiếp nhận câu hỏi tự nhiên từ kỹ sư, phân tích ý định và lập kế hoạch truy xuất đa bước (Multi-step plan).
2. Action (Hành động): Quyết định gọi Text-Manual MCP Server hoặc Table/Register MCP Server tùy thuộc vào bản chất dữ liệu cần tra cứu.
3. Observation (Quan sát): Quan sát dữ liệu trả về từ MCP Servers, đối soát với ngữ cảnh tài liệu gốc.
4. Verification (Xác minh): Thực hiện kiểm tra chéo (Reflection) để đảm bảo tính đúng đắn của địa chỉ thanh ghi và thông số điện áp trước khi tổng hợp câu trả lời.

1.5.2 Tích hợp công cụ

- Text-Manual MCP Server: Quản lý truy xuất văn bản mô tả chức năng, ứng dụng và hướng dẫn lập trình từ Reference Manuals và Application Notes (Permission: Read-Only).
- Table/Register MCP Server: Tối ưu hóa riêng cho dữ liệu cấu trúc (bản đồ thanh ghi, địa chỉ bộ nhớ, Alternate Function pins, bảng đặc tính điện). Trích xuất chính xác 100% không qua chunking tự do (Permission: Read-Only).
- Filesystem MCP Server (Mở rộng): Cho phép ghi mã nguồn mẫu cấu hình vi điều khiển trực tiếp vào thư mục làm việc sau khi qua cổng xác nhận người dùng (Permission: Reversible-Write / Guarded Action).

1.5.3 Thiết kế bộ nhớ

- Short-term Memory: Lưu trữ ngữ cảnh câu hỏi hiện tại, các kế hoạch phân rã và kết quả trung gian từ các công cụ MCP.
- Episodic Memory Store: Lưu trữ lịch sử các câu hỏi tra cứu trước đó của kỹ sư để hỗ trợ các câu hỏi truy xuất nối tiếp mà không cần query lại database từ đầu.

1.6 Kế hoạch kiểm thử

Thử nghiệm 10+ trường hợp tấn công Prompt Injection. Tất cả các hành động có nguy cơ gây hại (cấu hình vượt ngưỡng Absolute Maximum Ratings) hoặc thao tác ghi file đều bắt buộc nằm sau cổng xác nhận người dùng (User Confirmation Gate).

1.7 Kế hoạch thực hiện

Tuần	Mục tiêu & Sản phẩm bàn giao	Phân công trách nhiệm
W1–W2	Hoàn thiện D1 Proposal.	Cả nhóm (Phân chia đồng đều)
W3–W4	Thu thập dữ liệu PDF (ESP32, STM32); Dựng hạ tầng MCP Servers (Text-MCP & Table-MCP).	Nhâm, Bình
W5–W6	Tích hợp Agent Loop (R1), Memory (R3), và lập bộ khung Đánh giá (Evaluation Harness).	Nhâm, Huy
W7	Nộp D2 Progress Report; Báo cáo Checkpoint Demo 8' (Live Demo trên 5-10 tasks).	Cả nhóm
W8–W9	Chạy kiểm thử diện rộng (40 tasks), thực hiện Ablation studies, chạy thử nghiệm Security/Injection.	Bình, Huy
W10–W12	Hoàn thiện Guardrails, tối ưu độ trễ/chi phí, đóng gói mã nguồn và bảo vệ D3 Final Defense.	Cả nhóm

Risk: TBD

1.8 AI-Use Statement

Nhóm sử dụng AI (Gemini / Claude) để hỗ trợ tìm kiếm tài liệu tham khảo, rà soát lỗi chính tả và gợi ý cấu trúc báo cáo. Toàn bộ kiến trúc hệ thống, mã nguồn MCP Servers, kịch bản thử nghiệm và phân tích dữ liệu đều do các thành viên trong nhóm tự thực hiện và kiểm chứng.

Tài liệu tham khảo

[1] D. Kong, N. Funabiki, H. H. S. Kyaw, I. N. D. Kotama, and Z. Zhu, "An AI answer-validation method using agentic RAG for datasheet inquiry for IoT application system deployment," *Future Internet*, vol. 18, no. 8, p. 442, 2026.

[2] A. Elewah, K. Elgazzar, and S. Elnaffar, "Agentic search engine for real-time Internet of Things data," *Sensors*, vol. 25, no. 19, p. 5995, 2025.

[3] M. Arazzi, M. M. Sciarroni, A. Nocera, and E. Storti, "RAG-IoE: IoT context-aware information retrieval with Large Language Models in Industry 5.0," *ACM Transactions on Internet of Things*, vol. 6, no. 4, art. 23, pp. 1–31, 2025.

[4] W. Zhang and J. Zhang, "Hallucination mitigation for retrieval-augmented large language models: A review," *Mathematics*, vol. 13, no. 5, p. 856, 2025.

[5] J. Dagdelen, A. Dunn, S. Lee, N. Walker, A. S. Rosen, G. Ceder, K. A. Persson, and A. Jain, "Structured information extraction from scientific text with large language models," *Nature Communications*, vol. 15, p. 1418, 2024.